



清华大学
Tsinghua University

第十章 隐马尔科夫模型



Andrey Markov

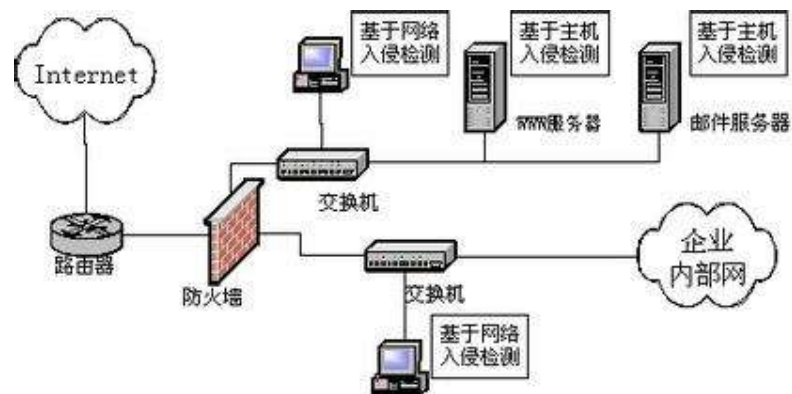
- 中文名 马尔科夫
- 国 籍 俄国
- 出生地 梁赞
- 出生日期 1856年6月14日
- 逝世日期 1922年7月20日
- 主要成就 开创了[随机过程](#)这个新领域






HMM应用

- 人脸识别
- 语音识别
- 入侵检测





例：





清华大学

Tsinghua University

隐马尔科夫模型的定义

- 隐马尔可夫模型是关于时序的概率模型;
- 描述由一个**隐藏**的马尔可夫链随机生成不可**观测的****状态随机序列**(state sequence), 再由各个状态生成一个观测而产生**观测随机序列**(observation sequence) 的过程, 序列的每一个位置又可以看作是一个时刻。



清华大学

Tsinghua University

隐马尔科夫模型

- 组成
 - 初始概率分布
 - 状态转移概率分布
 - 观测概率分布
 - Q: 所有可能状态的集合
 - V: 所有可能观测的集合

$$Q = \{q_1, q_2, \dots, q_N\}, \quad V = \{v_1, v_2, \dots, v_M\}$$

- I: 长度为T的状态序列
- O: 对应的观测序列

$$I = (i_1, i_2, \dots, i_T), \quad O = (o_1, o_2, \dots, o_T)$$



隐马尔科夫模型

- 组成
 - A: 状态转移概率矩阵

$$A = [a_{ij}]_{N \times N}$$

$$a_{ij} = P(i_{t+1} = q_j | i_t = q_i), \quad i = 1, 2, \dots, N; \quad j = 1, 2, \dots, N$$

时刻 t 处于状态 q_i 的条件下在时刻 $t+1$ 转移到状态 q_j 的概率



隐马尔科夫模型

- 组成

- B: 观测概率矩阵

$$B = [b_j(k)]_{N \times M}$$

$$b_j(k) = P(o_t = v_k | i_t = q_j), \quad k = 1, 2, \dots, M; \quad j = 1, 2, \dots, N$$

在时刻 t 处于状态 q_j 的条件下生成观测 v_k 的概率

- π : 初始状态概率向量

$$\pi_i = P(i_1 = q_i), \quad i = 1, 2, \dots, N$$

时刻 $t=1$ 处于状态 q_i 的概率



隐马尔科夫模型

- 三要素

$$\lambda = (A, B, \pi)$$

- 两个基本假设

- 齐次马尔科夫性假设，隐马尔可分链t的状态只和t-1状态有关：

$$P(i_t | i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(i_t | i_{t-1}), \quad t = 1, 2, \dots, T$$

- 观测独立性假设，观测只和当前时刻状态有关；

$$P(o_t | i_T, o_T, i_{T-1}, o_{T-1}, \dots, i_{t+1}, o_{t+1}, i_t, i_{t-1}, o_{t-1}, \dots, i_1, o_1) = P(o_t | i_t)$$



例：盒子和球模型

- 盒子: 1 2 3 4
- 红球: 5 3 6 8
- 白球: 5 7 4 2

- 转移规则:
 - 盒子1 下一个 盒子2
 - 盒子2或3 下一个 0.4 左, 0.6右
 - 盒子4 下一个 0.5 自身, 0.5盒子3
- 重复5次: $O = \{\text{红, 红, 白, 白, 红}\}$



例：盒子和球模型

- 状态集合： $Q=\{\text{盒子1, 盒子2, 盒子3, 盒子4}\}$, $N=4$
- 观测集合： $V=\{\text{红球, 白球}\}$ $M=2$
- 初始化概率分布：

$$\pi = (0.25, 0.25, 0.25, 0.25)^T$$

- 状态转移矩阵：

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0.4 & 0 & 0.6 & 0 \\ 0 & 0.4 & 0 & 0.6 \\ 0 & 0 & 0.5 & 0.5 \end{bmatrix}$$

- 观测矩阵：

$$B = \begin{bmatrix} 0.5 & 0.5 \\ 0.3 & 0.7 \\ 0.6 & 0.4 \\ 0.8 & 0.2 \end{bmatrix}$$



观测序列的生成过程

算法 10.1（观测序列的生成）

输入：隐马尔可夫模型 $\lambda = (A, B, \pi)$ ，观测序列长度 T ；

输出：观测序列 $O = (o_1, o_2, \dots, o_T)$ 。

- (1) 按照初始状态分布 π 产生状态 i_1
- (2) 令 $t = 1$
- (3) 按照状态 i_t 的观测概率分布 $b_{i_t}(k)$ 生成 o_t
- (4) 按照状态 i_t 的状态转移概率分布 $\{a_{i_t i_{t+1}}\}$ 产生状态 i_{t+1} ， $i_{t+1} = 1, 2, \dots, N$
- (5) 令 $t = t + 1$ ；如果 $t < T$ ，转步 (3)；否则，终止



隐马尔科夫模型的三个基本问题

- 1、概率计算问题
 - 给定: $\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$
 - 计算: $P(O|\lambda)$
- 2、学习问题
 - 已知: $O = (o_1, o_2, \dots, o_T)$
 - 估计: $\lambda = (A, B, \pi)$, 使 $P(O|\lambda)$ 最大
- 3、预测问题 (解码)
 - 已知: $\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$
 - 求: 使 $P(I|O)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$



概率计算方法

- 直接计算法
 - 给定模型: $\lambda = (A, B, \pi)$ 和观测概率: $O = (o_1, o_2, \dots, o_T)$
 - 计算: $P(O | \lambda)$
- 最直接的方法:
 - 列举所有可能的长度为T状态序列 $I = (i_1, i_2, \dots, i_T)$
 - 求各个状态序列I与观测序列 $O = (o_1, o_2, \dots, o_T)$ 的联合概率 $P(O, I | \lambda)$
 - 然后对所有可能的状态序列求和, 得到 $P(O | \lambda)$



概率计算方法

- 直接计算法

- 状态序列 $I = (i_1, i_2, \dots, i_T)$ 概率: $P(I | \lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T}$

- 对固定的状态序列 I , 观测序列 O 的概率: $P(O | I, \lambda)$

$$P(O | I, \lambda) = b_{i_1}(o_1) b_{i_2}(o_2) \dots b_{i_T}(o_T)$$

- O 和 I 同时出现的联合概率为:

$$\begin{aligned} P(O, I | \lambda) &= P(O | I, \lambda) P(I | \lambda) \\ &= \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T) \end{aligned}$$

- 对所有可能的状态序列 I 求和, 得到观测 O 的概率:

$$\begin{aligned} P(O | \lambda) &= \sum_I P(O | I, \lambda) P(I | \lambda) \\ &= \sum_{i_1, i_2, \dots, i_T} \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \dots a_{i_{T-1} i_T} b_{i_T}(o_T) \end{aligned}$$

复杂度

$O(TN^T)$



前向算法

- 前向概率定义：给定隐马尔科夫模型 λ ，定义到时刻 t 部分观测序列为： o_1, o_2, \dots, o_t ，且状态为 q_i 的概率为前向概率，记作： $\alpha_t(i) = P(o_1, o_2, \dots, o_t, i_t = q_i | \lambda)$

算法 10.2（观测序列概率的前向算法）

输入：隐马尔可夫模型 λ ，观测序列 O ；

输出：观测序列概率 $P(O | \lambda)$ 。

- 初值： $\alpha_1(i) = \pi_i b_i(o_1)$ ， $i = 1, 2, \dots, N$
- 递推：
$$\alpha_{t+1}(i) = \left[\sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N$$
- 终止：
$$P(O | \lambda) = \sum_{i=1}^N \alpha_T(i)$$




前向算法

• 因为: $\alpha_T(i) = P(o_1, o_2, \dots, o_T, i_T = q_i | \lambda)$

• 所以:
$$P(O | \lambda) = \sum_{i=1}^N \alpha_T(i)$$

• 递推:



复杂度

$O(N^2T)$



前向算法

- 减少计算量的原因在于每一次计算，直接引用前一个时刻的计算结果，避免重复计算。




图 10.2 观测序列路径结构

复杂度

$$O(N^2T)$$



例：

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

设 $T=3$ ， $O=(\text{红}, \text{白}, \text{红})$ ，试用前向算法计算 $P(O|\lambda)$

解 按照算法 10.2

(1) 计算初值

$$\alpha_1(1) = \pi_1 b_1(o_1) = 0.10$$

$$\alpha_1(2) = \pi_2 b_2(o_1) = 0.16$$

$$\alpha_1(3) = \pi_3 b_3(o_1) = 0.28$$



(2) 递推计算

例：

$$\alpha_2(1) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i1} \right] b_1(o_2) = 0.154 \times 0.5 = 0.077$$

$$\alpha_2(2) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i2} \right] b_2(o_2) = 0.184 \times 0.6 = 0.1104$$

$$\alpha_2(3) = \left[\sum_{i=1}^3 \alpha_1(i) a_{i3} \right] b_3(o_2) = 0.202 \times 0.3 = 0.0606$$

$$\alpha_3(1) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i1} \right] b_1(o_3) = 0.04187$$

$$\alpha_3(2) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i2} \right] b_2(o_3) = 0.03551$$

$$\alpha_3(3) = \left[\sum_{i=1}^3 \alpha_2(i) a_{i3} \right] b_3(o_3) = 0.05284$$



例： (3) 终止

$$P(O|\lambda) = \sum_{i=1}^3 \alpha_3(i) = 0.13022$$



后向算法

- 定义10.3 后向概率：给定隐马尔科夫模型 λ ，定义在时刻 t 状态为 q_i 的条件下，从 $t+1$ 到 T 的部分观测序列为： $o_{t+1}, o_{t+2}, \dots, o_T$ 的概率为后向概率，记作：

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T \mid i_t = q_i, \lambda)$$

可以用递推的方法求得后向概率 $\beta_t(i)$ 及观测序列概率 $P(O \mid \lambda)$



后向算法

算法 10.3 (观测序列概率的后向算法)

输入：隐马尔可夫模型 λ ，观测序列 O ；

输出：观测序列概率 $P(O|\lambda)$ 。

(1)

$$\beta_T(i) = 1, \quad i = 1, 2, \dots, N$$

(2) 对 $t = T-1, T-2, \dots, 1$


$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N$$

(3)

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i)$$



后向算法



- 前向后向统一写为：（ $t=1$ 和 $t=T-1$ 分别对应）

$$P(O|\lambda) = \sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad t=1, 2, \dots, T-1$$



一些概率和期望值的计算

1. 给定模型 λ 和观测 O ，在时刻 t 处于状态 q_i 的概率。

记 $\gamma_t(i) = P(i_t = q_i | O, \lambda)$

$$\gamma_t(i) = P(i_t = q_i | O, \lambda) = \frac{P(i_t = q_i, O | \lambda)}{P(O | \lambda)}$$

$$\alpha_t(i)\beta_t(i) = P(i_t = q_i, O | \lambda)$$

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O | \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$



一些概率和期望值的计算

2. 给定模型 λ 和观测 O ，在时刻 t 处于状态 q_i 且在时刻 $t+1$ 处于状态 q_j 的概率。记

$$\xi_t(i, j) = P(i_t = q_i, i_{t+1} = q_j | O, \lambda)$$

通过前向后向概率计算：

$$\xi_t(i, j) = \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{P(O | \lambda)} = \frac{P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}{\sum_{i=1}^N \sum_{j=1}^N P(i_t = q_i, i_{t+1} = q_j, O | \lambda)}$$

$$P(i_t = q_i, i_{t+1} = q_j, O | \lambda) = \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)$$

$$\xi_t(i, j) = \frac{\alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i) a_{ij} b_j(o_{t+1}) \beta_{t+1}(j)}$$



清华大学

Tsinghua University

一些概率和期望值的计算

3. 将 $\gamma_t(i)$ 和 $\xi_t(i, j)$ 对各个时刻 t 求和, 可以得到一些有用的期望值:

(1) 在观测 O 下状态 i 出现的期望值

$$\sum_{t=1}^T \gamma_t(i)$$

(2) 在观测 O 下由状态 i 转移的期望值

$$\sum_{t=1}^{T-1} \gamma_t(i)$$

(3) 在观测 O 下由状态 i 转移到状态 j 的期望值

$$\sum_{t=1}^{T-1} \xi_t(i, j)$$



学习算法

- 监督学习方法:

- 假设训练数据是包括观测序列 O 和对应的状态序列 I

$$\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$$

- 可以利用极大似然估计法来估计隐马尔可夫模型参数。

- 非监督学习方法:

- 假设训练数据只有 S 个长度为 T 的观测序 $\{O_1, O_2, \dots, O_S\}$,
 - 采用Baum-Welch算法



监督学习方法

- 已知: $\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$
- 1、转移概率 a_{ij} 的估计:
- 设样本中时刻 t 处于状态 i , 时刻 $t+1$ 转移到状态 j 的频数为 A_{ij} , 那么状态转移概率 a_{ij} 的估计是:

$$\hat{a}_{ij} = \frac{A_{ij}}{\sum_{j=1}^N A_{ij}}, \quad i=1, 2, \dots, N; \quad j=1, 2, \dots, N$$



监督学习方法

- 已知: $\{(O_1, I_1), (O_2, I_2), \dots, (O_S, I_S)\}$
- 2、观测概率 $b_j(k)$ 的估计: 设样本中状态为 j 并观测为 k 的频数是 $B_j(k)$, 那么状态为 j 观测为 k 的概率

$$\hat{b}_j(k) = \frac{B_{jk}}{\sum_{k=1}^M B_{jk}}, \quad j=1, 2, \dots, N; \quad k=1, 2, \dots, M$$

- 3、初始状态概率 π_i 的估计 $\hat{\pi}_i$ 为 S 个样本中初始状态为 q_i 的频率。
- 往往人工标注数据很贵



Baum-Welch算法

- 假定训练数据只包括 $\{O_1, O_2, \dots, O_s\}$,
- 求模型参数 $\lambda = (A, B, \pi)$
- 实质上是有隐变量的概率模型: EM算法

$$P(O|\lambda) = \sum_I P(O|I, \lambda) P(I|\lambda)$$

- 1、确定完全数据的对数似然函数
- 完全数据 $(O, I) = (o_1, o_2, \dots, o_T, i_1, i_2, \dots, i_T)$
- 完全数据的对数似然函数 $\log P(O, I|\lambda)$



Baum Welch算法

- 2、EM的E步 求 Q 函数 $Q(\lambda, \bar{\lambda})$

$$Q(\lambda, \bar{\lambda}) = \sum_I \log P(O, I | \lambda) P(O, I | \bar{\lambda})$$

$$P(O, I | \lambda) = \pi_{i_1} b_{i_1}(o_1) a_{i_1 i_2} b_{i_2}(o_2) \cdots a_{i_{T-1} i_T} b_{i_T}(o_T)$$

- 则：

$$\begin{aligned} Q(\lambda, \bar{\lambda}) = & \sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) \\ & + \sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) + \sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) \end{aligned}$$

- 对序列总长度T进行



Baum Welch算法

- 3、EM算法的M步，极大化 $Q(\lambda, \bar{\lambda})$ 求模型参数A,B, π

第一项:
$$\sum_I \log \pi_{i_1} P(O, I | \bar{\lambda}) = \sum_{i=1}^N \log \pi_{i_1} P(O, i_1 = i | \bar{\lambda})$$

由约束条件: $\sum_{i=1}^N \pi_i = 1$ 利用拉格朗日乘子:

$$\sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right)$$

求偏导数，并结果为0

- $$\frac{\partial}{\partial \pi_i} \left[\sum_{i=1}^N \log \pi_i P(O, i_1 = i | \bar{\lambda}) + \gamma \left(\sum_{i=1}^N \pi_i - 1 \right) \right] = 0$$

- 得:
$$P(O, i_1 = i | \bar{\lambda}) + \gamma \pi_i = 0 \quad \gamma = -P(O | \bar{\lambda}) \quad \pi_i = \frac{P(O, i_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})}$$



清华大学

Tsinghua University

学习算法 Baum Welch算法

- 3、EM算法的M步，极大化 $Q(\lambda, \bar{\lambda})$ 求A,B, π

第二项可写成：

$$\sum_I \left(\sum_{t=1}^{T-1} \log a_{i_t i_{t+1}} \right) P(O, I | \bar{\lambda}) = \sum_{i=1}^N \sum_{j=1}^N \sum_{t=1}^{T-1} \log a_{ij} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})$$

由约束条件 $\sum_{j=1}^N a_{ij} = 1$ ，拉格朗日乘子法：

- 得：

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, i_t = i, i_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, i_t = i | \bar{\lambda})}$$



Baum Welch算法

- 3、EM算法的M步，极大化 $Q(\lambda, \bar{\lambda})$ 求A,B, π

第三项：

$$\sum_I \left(\sum_{t=1}^T \log b_{i_t}(o_t) \right) P(O, I | \bar{\lambda}) = \sum_{j=1}^N \sum_{t=1}^T \log b_j(o_t) P(O, i_t = j | \bar{\lambda})$$

由约束条件：

$$\sum_{k=1}^M b_j(k) = 1$$

注意，只有在 $o_t = v_k$ 时 $b_j(o_t)$ 对 $b_j(k)$ 的偏导数才不为 0，

以 $I(o_t = v_k)$ 表示，求得

$$b_j(k) = \frac{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda}) I(o_t = v_k)}{\sum_{t=1}^T P(O, i_t = j | \bar{\lambda})}$$



学习算法 Baum Welch算法

- 将已上得到的概率分别用 $\gamma_t(i)$, $\xi_t(i, j)$ 表示:

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$

$$b_j(k) = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$

$$\pi_i = \gamma_1(i)$$



清华大学

Tsinghua University

学习算法 Baum Welch算法

算法 10.4 (Baum-Welch 算法)

输入：观测数据 $O = (o_1, o_2, \dots, o_T)$ ；

输出：隐马尔可夫模型参数。

(1) 初始化

对 $n=0$ ，选取 $a_{ij}^{(0)}$ ， $b_j(k)^{(0)}$ ， $\pi_i^{(0)}$ ，得到模型 $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$

(2) 递推。对 $n=1, 2, \dots$ ，

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad b_j(k)^{(n+1)} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$
$$\pi_i^{(n+1)} = \gamma_1(i)$$

右端各值按观测 $O = (o_1, o_2, \dots, o_T)$ 和模型 $\lambda^{(n)} = (A^{(n)}, B^{(n)}, \pi^{(n)})$ 计算

(3) 终止。得到模型参数 $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$



预测算法

- 近似算法

- 想法：在每个时刻t选择在该时刻最有可能出现的状态 i_t^* ，从而得到一个状态序列 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 将它作为预测的结果，在时刻t处于状态 q_i 的概率：

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

- 在每一时刻t最有可能的状态是： $i_t^* = \arg \max_{1 \leq i \leq N} [\gamma_t(i)]$ ， $t = 1, 2, \dots, T$

从而得到状态序列： $I^* = (i_1^*, i_2^*, \dots, i_T^*)$

得到的状态有可能实际不发生



维特比算法

- Viterbi 方法
- 用动态规划解概率最大路径，一个路径对应一个状态序列。
- 最优路径具有这样的特性：如果最优路径在时刻 t 通过结点 i_t^* ，那么这一路径从结点 i_t^* 到终点 i_T^* 的部分路径，对于从 i_t^* 到 i_T^* 的所有可能的部分路径来说，必须是最优的。
- 只需从时刻 $t=1$ 开始，递推地计算在时刻 t 状态为 i 的各条部分路径的最大概率，直至得到时刻 $t=T$ 状态为 i 的各条路径的最大概率，时刻 $t=T$ 的最大概率即为最优路径的概率 P^* ，最优路径的终结点 i_T^* 也同时得到。
- 之后，为了找出最优路径的各个结点，从终结点开始，由后向前逐步求得结点 i_{T-1}^*, \dots, i_1^* ，得到最优路径

$$I^* = (i_1^*, i_2^*, \dots, i_T^*)$$



维特比算法

- 导入两个变量 δ 和 ψ ，定义在时刻 t 状态为 i 的所有单个路径 (i_1, i_2, \dots, i_t) 中概率最大值为：

$$\delta_t(i) = \max_{i_1, i_2, \dots, i_{t-1}} P(i_t = i, i_{t-1}, \dots, i_1, o_t, \dots, o_1 | \lambda), \quad i = 1, 2, \dots, N$$

- 由定义可得变量 δ 的递推公式：

$$\begin{aligned} \delta_{t+1}(i) &= \max_{i_1, i_2, \dots, i_t} P(i_{t+1} = i, i_t, \dots, i_1, o_{t+1}, \dots, o_1 | \lambda) \\ &= \max_{1 \leq j \leq N} [\delta_t(j) a_{ji}] b_i(o_{t+1}), \quad i = 1, 2, \dots, N; \quad t = 1, 2, \dots, T-1 \end{aligned}$$

- 定义在时刻 t 状态为 i 的所有单个路径中概率最大的路径的第 $t-1$ 个结点为 $(i_1, i_2, \dots, i_{t-1}, i)$

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$



Viterbi 方法

算法 10.5 (维特比算法)

输入: 模型 $\lambda = (A, B, \pi)$ 和观测 $O = (o_1, o_2, \dots, o_T)$;

输出: 最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$.

(1) 初始化

$$\delta_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

$$\psi_1(i) = 0, \quad i = 1, 2, \dots, N$$

(2) 递推. 对 $t = 2, 3, \dots, T$

$$\delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad i = 1, 2, \dots, N$$

$$\psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N$$



Viterbi 方法

(3) 终止

$$P^* = \max_{1 \leq i \leq N} \delta_T(i)$$

$$i_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

(4) 最优路径回溯. 对 $t = T-1, T-2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*)$$

求得最优路径 $I^* = (i_1^*, i_2^*, \dots, i_T^*)$



例

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, \quad B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \quad \pi = (0.2, 0.4, 0.4)^T$$

$O = (\text{红}, \text{白}, \text{红})$ ，试求最优状态序列，即最优路径 $I^* = (i_1^*, i_2^*, i_3^*)$

- 1、初始化：在 $t=1$ 时，对每一个状态 i ， $i=1,2,3$ ，求状态 i 观测 O_1 为红的概率，记为： $\delta_1(i)$

$$\delta_1(i) = \pi_i b_i(o_1) = \pi_i b_i(\text{红}), \quad i=1,2,3$$

- 代入实际数据： $\delta_1(1)=0.10$ ， $\delta_1(2)=0.16$ ， $\delta_1(3)=0.28$

$$\text{记 } \psi_1(i) = 0, \quad i=1,2,3$$



例




图 10.4 求最优路径



例

- 2、在 $t=2$ 时，对每一个状态 i ， $i=1,2,3$ ，求在 $t=1$ 时状态为 j 观测 O_1 为红并在 $t=2$ 时状态为 i 观测 O_2 为白的路径的最大概率，记为 $\delta_2(i)$

$$\delta_2(i) = \max_{1 \leq j \leq 3} [\delta_1(j) a_{ji}] b_i(o_2)$$

- 同时，对每个状态 i ，记录概率最大路径的前一个状态 j

$$\psi_2(i) = \arg \max_{1 \leq j \leq 3} [\delta_1(j) a_{ji}], \quad i = 1, 2, 3$$



清华大学

Tsinghua University

例

计算:

$$\begin{aligned}\delta_2(1) &= \max_{1 \leq j \leq 3} [\delta_1(j) a_{j1}] b_1(o_2) \\ &= \max_j \{0.10 \times 0.5, 0.16 \times 0.3, 0.28 \times 0.2\} \times 0.5 \\ &= 0.028\end{aligned}$$

$$\psi_2(1) = 3$$

$$\delta_2(2) = 0.0504, \quad \psi_2(2) = 3$$

$$\delta_2(3) = 0.042, \quad \psi_2(3) = 3$$

同样, 在 $t=3$ 时

$$\delta_3(i) = \max_{1 \leq j \leq 3} [\delta_2(j) a_{ji}] b_i(o_3)$$

$$\psi_3(i) = \arg \max_{1 \leq j \leq 3} [\delta_2(j) a_{ji}]$$

$$\delta_3(1) = 0.00756, \quad \psi_3(1) = 2$$

$$\delta_3(2) = 0.01008, \quad \psi_3(2) = 2$$

$$\delta_3(3) = 0.0147, \quad \psi_3(3) = 3$$



例

- 3、以 P^* 表示最优路径的概率：

$$P^* = \max_{1 \leq i \leq 3} \delta_3(i) = 0.0147$$

- 最优路径的终点是：

$$i_3^* = \arg \max_i [\delta_3(i)] = 3$$

- 4、由最优路径的终点 i_3^* ，逆向找到 i_2^*, i_1^*

$$\text{在 } t=2 \text{ 时, } i_2^* = \psi_3(i_3^*) = \psi_3(3) = 3$$

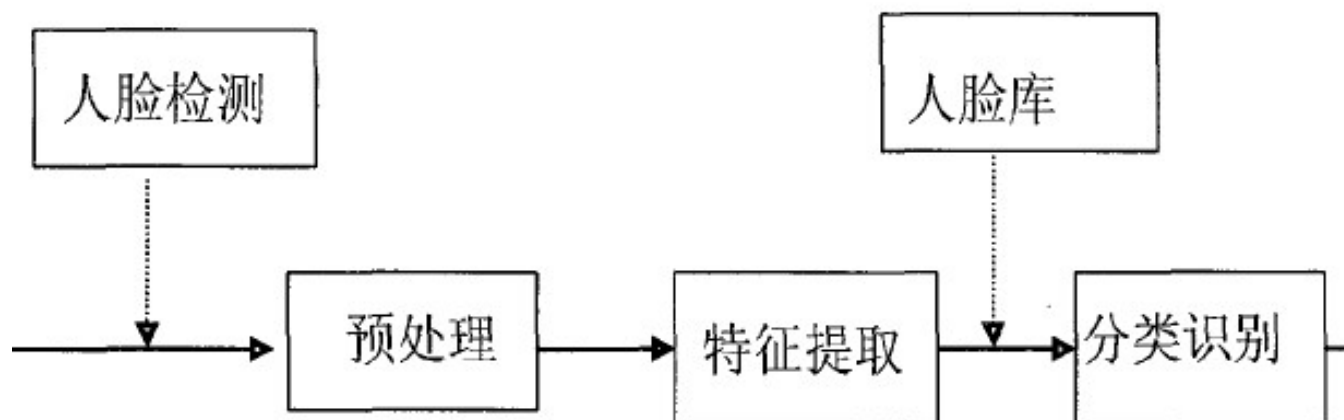
$$\text{在 } t=1 \text{ 时, } i_1^* = \psi_2(i_2^*) = \psi_2(3) = 3$$

- 于是求得最优路径，即最优状态序列：

$$I^* = (i_1^*, i_2^*, i_3^*) = (3, 3, 3)$$



人脸检测





人脸检测

- 人脸图像预处理

- 光线补偿

$$I_{ave} = \frac{1}{N} \sum_{i=1}^N I_i \quad I_{\text{modify}} = (127 - I_{ave}) + I_i$$

- 中值滤波

- 归一化处理

$$G(i, j) = \frac{I(i, j) - m}{v} \times sv + sm$$



清华大学

Tsinghua University

人脸识别

- HMM训练步骤： 对每个人脸建立一个HMM
- 1、人脸特征向量提取
- 2、建立公用的HMM模型
- 3、HMM初始参数确定
- 4、初始模型参数训练，主要是运用Viterbi算法训练均匀分割得到参数，求得最佳分割点，然后重新计算模型初始参数，直到模型收敛为止。
- 5、人脸模型训练过程，将(1)中得到的观测向量代入(4)中得到的模型参数进行训练，使用迭代方法调整模型参数达到最优。



清華大學

Tsinghua University

人脸检测

- 1、人脸特征向量提取：
 - 基于奇异值分解的特征提取
 - 离散余弦变换
 - 多维尺度分析(MDS)
 - 人脸等密度线分析匹配方法、
 - 弹性图匹配方法
 - ○ ○ ○



人脸检测

- SVD

奇异矩阵 A 可以分解为以下形式:



$$A = U \begin{pmatrix} \Delta & 0 \\ 0 & 0 \end{pmatrix} V^T$$

- 稳定性: 由于奇异值特征向量具有良好的稳定性, 所以它对图像噪音、图像光照条件引起的灰度变化具有不敏感的特性;
- 转置不变性: A 和 A 转置具有相同的奇异值;
- 旋转不变性: 图像 A 和旋转后的图像有相同的特征向量;
- 唯一不变性: 对矩阵 A 换两行或者两列仍然具有相同的特征向量;
- 镜像变换不变形:




人脸检测

- HMM模型
状态





人脸检测



$$T = \frac{H-L}{L-P} + 1$$



人脸检测

- 3、初始参数确定:

- $\pi = (1, 0, 0, 0, 0)$

- A矩阵:

$$A = \begin{bmatrix} \frac{19}{20} & \frac{1}{20} & 0 & 0 & 0 \\ 0 & \frac{19}{20} & \frac{1}{20} & 0 & 0 \\ 0 & 0 & \frac{19}{20} & \frac{1}{20} & 0 \\ 0 & 0 & 0 & \frac{19}{20} & \frac{1}{20} \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

- B矩阵: 用混合高斯模型, 则是将均匀分割后得到的五个部分中的每个部分, 使用K均值聚类, 将每个状态聚成M类, 然后分别计算每一类的均值和方差, 将这两个值分别赋给高斯模型。



人脸检测

- 初始模型
- 参数训练:

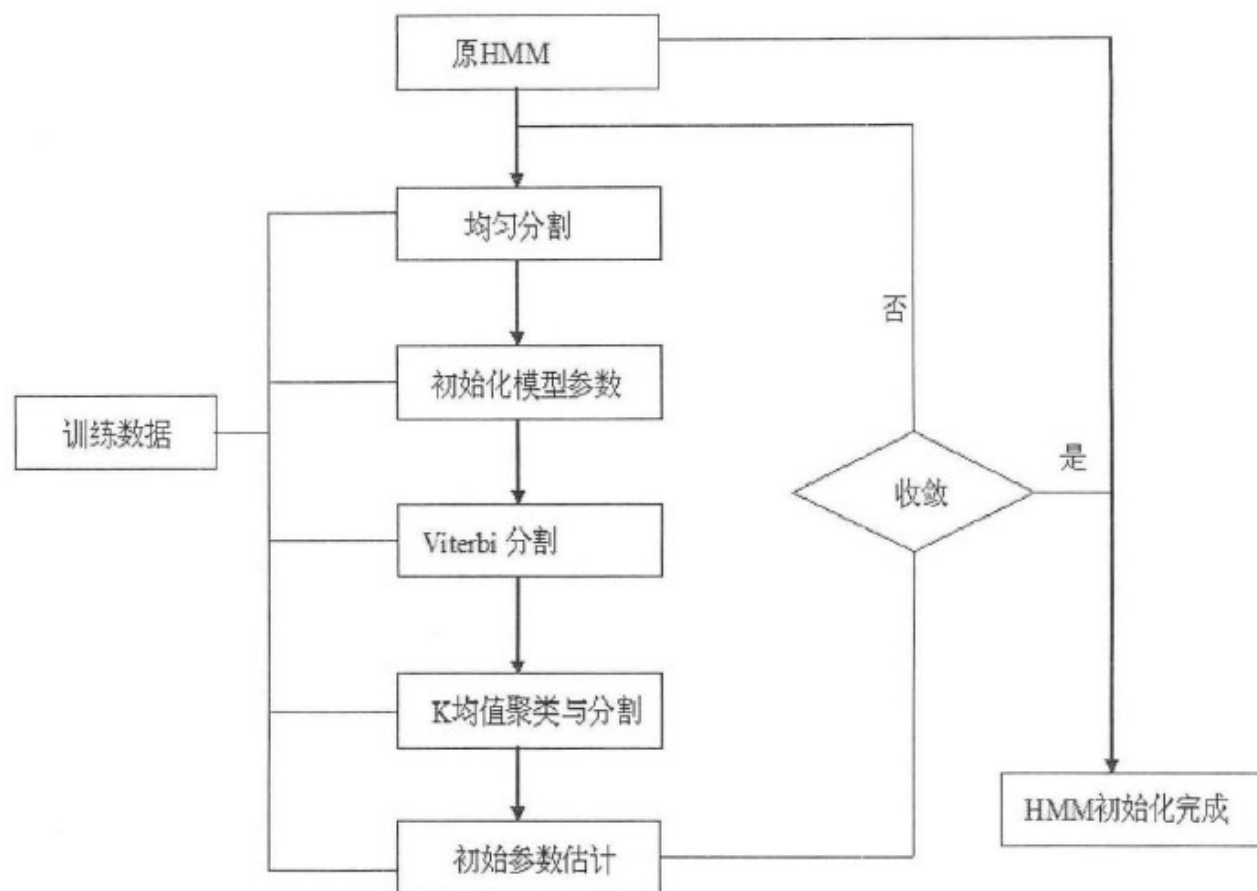


图4.2 HMM的初始化流程图



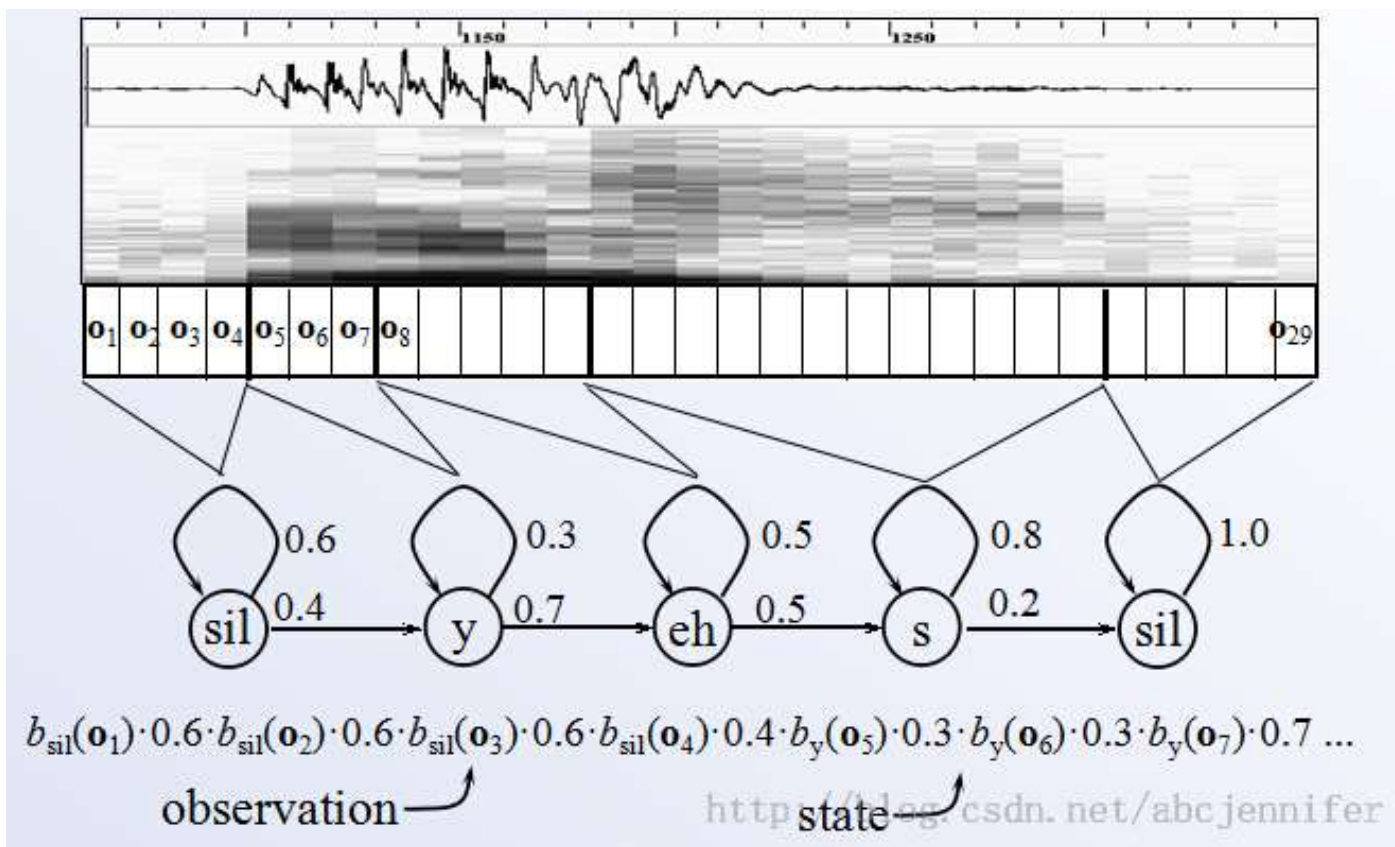
人脸检测

表 4.1 HMM 实验结果 (ORL)

	N=2	N=3	N=4
基于像素值特征的 HMM ^[46-47]	84%	84%	84%
基于 SVD 的 HMM	82.5%	86%	85.5%

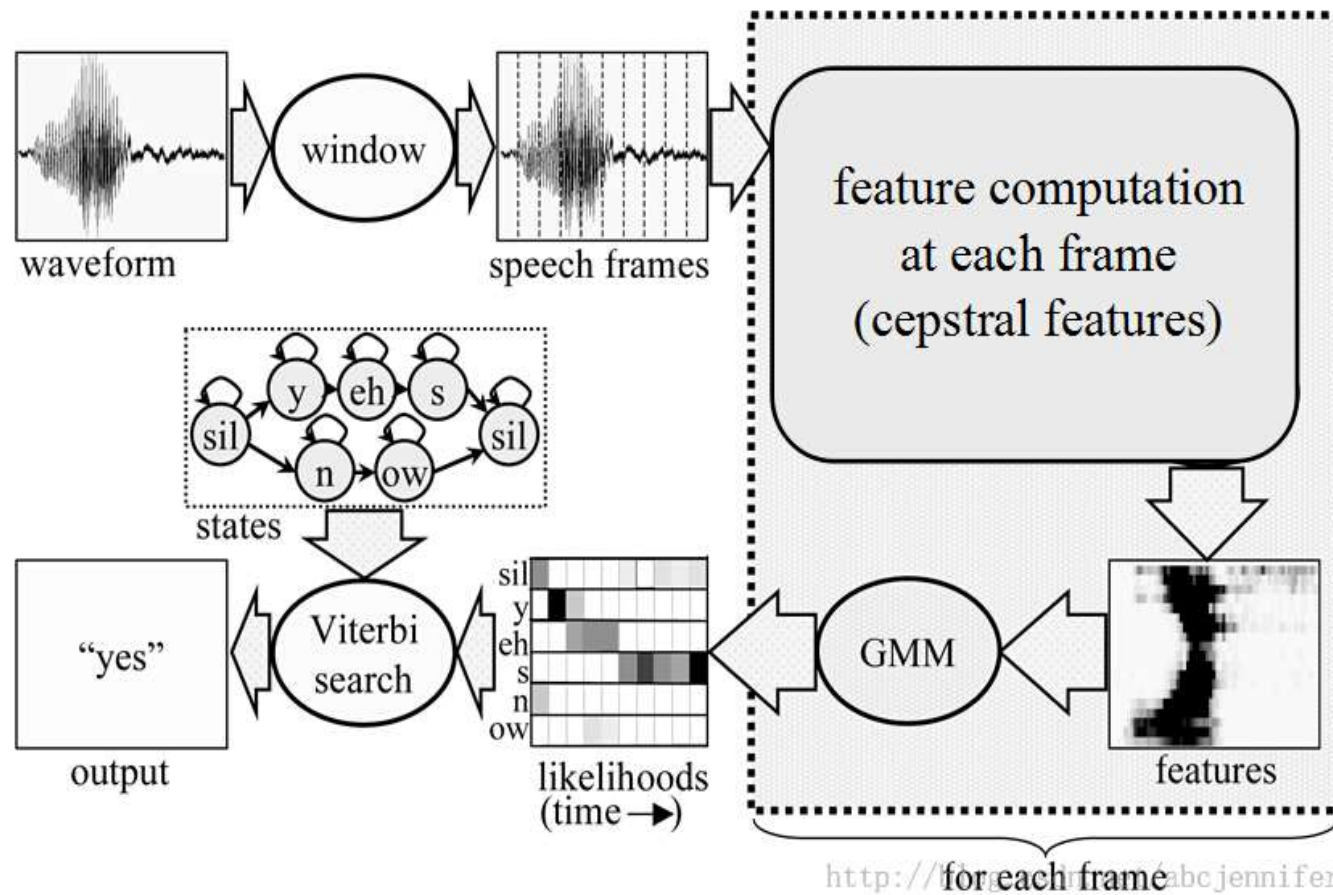


语音识别





语音识别





隐马尔科夫模型在入侵检测中的应用

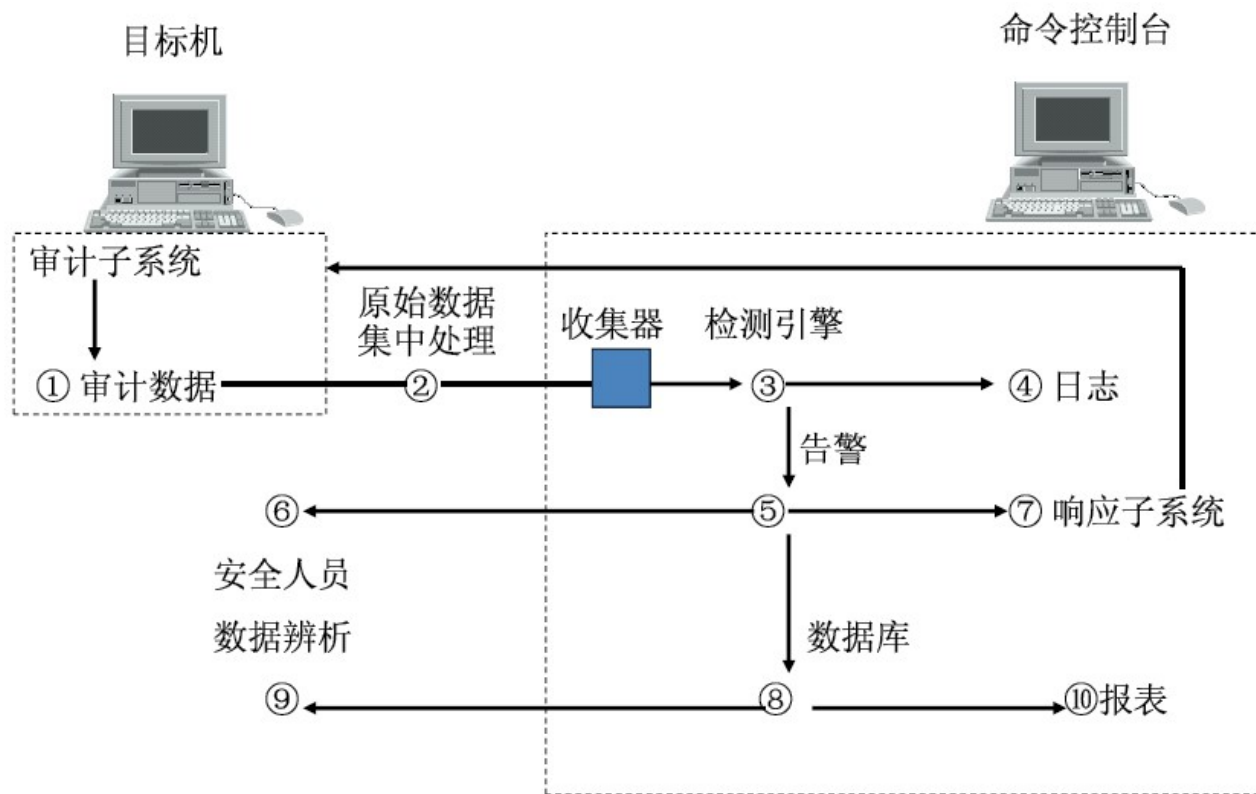
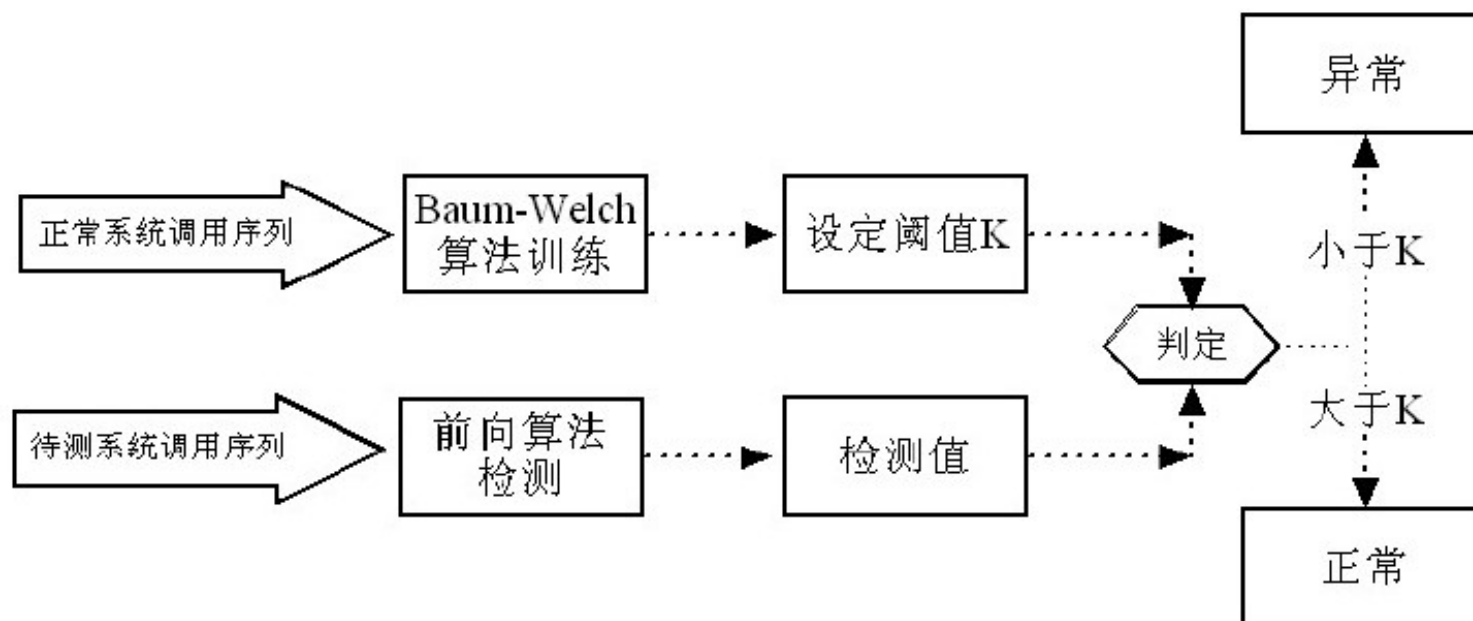


图15.2 集中式基于主机的入侵检测系统结构



隐马尔科夫模型在入侵检测中的应用





数据集

- 两种正常系统调用序列数据集。
- **Sendmail正常系统调用序列数据集**
- Sendmail的正常训练数据集是由1571583个系统调用构成的序列,这些系统调用分属147个不同的进程(在本实验中只考虑系统调用,不考虑进程)。
- Sendmail正常系统调用序列中包含48个唯一系统调用,这些系统调用的调用号为(按照序列中出现的顺序):4,2,66, 138, 5,23,45,27,167, 85,59,105, 104, 106, 56, 19, 155, 83, 93, 94, 112, 100, 50, 128, 89, 121, 11, 1, 40,38,18, 78,101,102,88,95,6,108, 32,1, 8,9, 14,17,3,124,41,61。



数据集

- **lpr的正常系统调用序列数据集**
- lpr的正常系统调用序列由2398个系统调用构成,分属9个进程,长度大约是sendmail 正常系统调用序列的六百五十五分之一。
- Lpr正常系统调用序列包含包含37个唯一系统调用,系统调用号分别为(按照序列中出现的顺序):4, 2, 66, 138, 5, 23, 45, 27, 105, 104, 106, 83, 59, 50, 88, 167, 17, 18, 155, 19, 127, 93, 100, 112, 143, 128, 85, 89, 121, 3, 56, 7, 119, 32, 9, 8, 94。



清华大学
Tsinghua University

- END
- Q&R